

Super-resolution imaging systems: an alternative to interpolation algorithms for spectral imaging

Luis Felipe Cruz -Juan Pablo Viviescas

Escuela de Ingeniería de sistemas

Universidad Industrial de Satander

Abstract—En este estudio se procesaron imágenes satelitales del sensor Landsat 8, donde está presente el área metropolitana de Bucaramanga, mediante los métodos de interpolación Bilineal, Bicubica, y Vecino mas cercano. Se compararon los resultados obtenidos y con la mejor imagen de estas se le aplicaron algoritmos de segmentación con superpixel, desarrollando así todo el flujo de trabajo que permitiría mejorar los procesos de clasificación de uso de suelo con cobertura vegetal.

Keywords: interpolacion, segmentacion por superpixel, super-resolucion, imagenes espectrales.

I. INTRODUCCIÓN

Las fotografías que nosotros acostumbramos a subir en nuestras redes están compuestas por píxeles, dependiendo de la calidad de nuestra cámara la resolución de nuestra imagen mejora, pero que sucede si tomamos una imagen que salga borrosa o que no se vea muy bien nos preguntamos ¿Habrá una manera de mejorar esta imagen para que se vea mejor? Y la respuesta es sí ya que existen diferentes algoritmos que pueden mejorar dicha imagen.

Uno de los métodos más utilizados para mejorar la resolución de las imágenes es por medio de la interpolación de imágenes que consiste en tomar múltiples imágenes de un objeto de interés y construir una nueva imagen con la información de todas las imágenes que tomamos anteriormente, sin embargo existe múltiples alternativas que nos permiten mejorar la imagen además obteniendo nuevos datos que nos servirán para encontrar nuevas detalles en la imagen, como por ejemplo la super resolución de imágenes por medio de segmentación

II. MARCO TEÓRICO

Resolución espacial: se refiere a la finura de detalles visibles en una imagen, cuanto menor es el área terrestre representada por cada píxel en una imagen digital mayores son los detalles que pueden ser captados y mayor es la resolución espacial como podemos apreciar en la figura 1.

Resoluciónpectral: Consiste en dividir la imagen en varias bandas del espectro electromagnético como podemos apreciar en la figura 2.

super resolucion de imagenes: Conjunto de métodos para mejorar la resolución de una imagen

Interpolación de imágenes: es un método de que consiste en llenar la información faltante de la imágenes con nuevos datos subministrados por algoritmos.

los algoritmos que se usaron en este proyecto fueron:

-Interpolación Bicúbica: Usando la interplacion[4] kernel donde α es un parametro, esta función deriva de encontrar un polinomio cubico a trozos con nudos que sean simétricos y que sea continua en $-2 \leq t \leq 2$. estas condiciones dejan un grado restante de libertad representado α en para cualquier valor de α , k_1 tienen puntos extremos $t = 0$ y $\pm 4/3$

$$k_1(t) = \begin{cases} (\alpha + 2)|t|^3 - (\alpha + 3)|t|^2 + 1 & \text{si } |t| \leq 1 \\ \alpha|t|^3 - 5\alpha|t|^2 + 8\alpha|t| + 4\alpha & \text{si } 1 < |t| < 2 \\ 0 & \text{si } \text{otrolado} \end{cases} \quad (1)$$

-Interpolación bilineal(con afilado): [4] La interpolacion bilineal por si sola no se considera muy buena, ya que al ampliar la imagen se ve un poco borrosa, para corregir esta característica se usa un proceso de nitidez que consiste en ampliar los bordes de las imágenes y mantener las áreas homogéneas no afectadas, para ello se usa operadores de gradiente, sobel, Prewitt o LaPlace, tenemos un operador gradiente Δ y definimos el afilado de la imagen $f : W \times H \rightarrow L$ con un peso de $\gamma \in [0,1]$ como nueva imagen $f^s : W \times H \rightarrow L$ le asignamos a cada $(x,y) \in W \times H$ el valor a ventaja de utilizar el operador de LaPlace para el afilado se debe a la complejidad computacional, ya que en LaPlace es mucho menor.

$$f^s(x,y) = f(x,y) + \gamma \delta f(x,y) \quad (2)$$

Para la nitidez de la imagen de la imagen, un operador de gradiente tiene una posición dominante, el operador de gradiente LaPlace se representa con su máscara:

$$M = \begin{bmatrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{bmatrix}.$$

-Interpolación vecino más cercano: [6] es una interpolación muy simple, en este método cada pixel de salida se le asigna un valor del punto de muestra más cercano en la entrada.

$$h(x) = \begin{cases} 0 & \text{si } |x| > 0 \\ 1 & \text{si } |x| < 0 \end{cases} \quad (3)$$

La frecuencia en que responde el vecino más cercano es $H(\omega) = \text{sinc}(\omega/2)$

Aunque este método es muy eficaz, la calidad de la imagen es muy mala, Es porque la transformada de fourier de una función rectangular es equivalente a una función sinc, con su ganancia en banda de paso cae rápidamente.

Segmentación:Cosiste en dividir una imagen en varias regiones conformada por grupo de píxeles denominados segmentos, en otras palabras consiste en un proceso de clasificación por pixel en el cual se le asigna una categoría a cada pixel de la imagen analizada, los algoritmos de segmentación utilizados son los siguientes:

-Segmentación slic:[5] Nuestro enfoque genera superpíxeles agrupando píxeles en función de su similitud de colores y proximidad en el plano imagen. Esto se hace en el espacio [labxy] de cinco dimensiones, donde [lab] es el vector de color de píxeles en el espacio de color CIELAB, que se considera ampliamente como perceptualmente uniforme para distancias de color pequeñas, y es la posición de los píxeles.

Si bien la distancia máxima posible entre dos colores en el espacio CIELAB (asumiendo imágenes de entrada sRGB) es limitada, la distancia espacial en el plano x depende del tamaño de la imagen. No es posible simplemente usar la distancia euclídea en este espacio 5D sin normalizar las distancias espaciales. Para agrupar píxeles en este espacio 5D, por lo tanto, introducimos una nueva medida de distancia que considera el tamaño de superpíxel. Al usarlo, hacemos cumplir la similitud de color, así como la proximidad de píxeles en este espacio 5D, de modo que los tamaños de clúster esperados y su extensión espacial sean aproximadamente iguales.

La medida de distancia nuestro algoritmo toma como entrada un número deseado de superpíxeles K de aproximadamente el mismo tamaño. Para una imagen con N píxeles, el tamaño aproximado de cada superpíxel es, por lo tanto, N / K píxeles. Para superpíxeles de aproximadamente el mismo tamaño, habría un centro de superpíxeles en cada intervalo de cuadrícula $s = \sqrt{N/K}$.

Al inicio del algoritmo debemos elegir como custer de los superpixeles $c_k = [l_k, a_k, b_k, x_k, y_k]$ con $k = [1, k]$ en intervalos regulares de cuadrícula, dado que la extensión espacial de cualquier superpixel es aproximadamente s^2 (el área aproximada del superpíxel) Podemos asumir con seguridad que los píxeles que están asociados con este centro de clúster se encuentran dentro de un área de $2S \times 2S$ alrededor del centro de superpíxeles en el plano xi. Esto se convierte en el área de búsqueda de los píxeles más cercanos a cada centro de clúster.

Las distancias euclidianas en el espacio de color son perceptualmente significativas para distancias pequeñas Si las distancias espaciales de píxeles exceden este límite de distancia de color perceptual, entonces comienzan a pesar más que las similitudes de color de los píxeles Por lo tanto, en lugar de usar una norma euclídea simple en el espacio 5D, usamos una medida de distancia D_s definida de la siguiente manera:

$$d_{lab} = \sqrt{(l_k - l_i)^2 + (a_k - a_i)^2 + (b_k - b_i)^2} \quad (4)$$

$$d_{xy} = \sqrt{(x_k - x_i)^2 + (y_k - y_i)^2} \quad (5)$$

$$D_s = d_{lab} + \frac{m}{S} d_{xy} \quad (6)$$

Donde D_s es la suma de la distancia lab y la distancia entre planos normalizada por el intervalo de cuadrícula S . Se introduce una variable en D que nos permite controlar la compacidad de un superpíxel. Cuanto mayor es el valor de m , más proximidad espacial se enfatiza y más compacto es el grupo.

-Segmentación Watershed: [2]Para esta segmentación utilizamos la transformación de cuenca Cabe señalar que podemos definir la cuenca hidrográfica de la función u o su gradiente: la diferencia entre las dos definiciones es que en el primer caso obtenemos las zonas de influencia de la imagen procesada, mientras que el segundo caso da los bordes de la imagen. En ambos casos, la cuenca proporciona una segmentación excesiva y para evitar este inconveniente se puede utilizar una técnica de marcadores. Proponemos en este apartado dar resultados numéricos basados en este método clásico según el trabajo de Beucher (1990), en el que el autor ha propuesto utilizar tanto las zonas de influencia como los mínimos de la imagen filtrada como criterio marcador.

Hemos considerado la misma imagen original que muestra anteriormente la cuenca hidrográfica de la imagen que muestra la cuenca hidrográfica de su gradiente. La segmentación excesiva se ve claramente. Mencionamos aquí que las pruebas numéricas dadas por dan una imagen segmentada con 1905 regiones para un tiempo computacional de 550 s. Esta segmentación excesiva se puede corregir en un primer paso aplicando un filtro morfológico que muestra la línea divisoria de la imagen filtrada: el número de regiones segmentadas se atenua (868 regiones) durante un tiempo computacional de 775 s, pero el resultado de la segmentación sigue siendo inaceptable **Segmentación felzenszwalb:** [1]El algoritmo de segmentación basado en gráficos de Felzenszwalb consta de cuatro pasos. En primer lugar, un gráfico G_{ph} con n vértices y m bordes se define como una entrada, $G_{ph} = (\text{Vert}, \text{Edg})$. La salida es una segmentación de Vert en componentes Seg , $\text{Seg} = (C_1, \dots, C_z)$.

El primer paso es clasificar Edg por peso de borde no decreciente en $c = (e_1, \dots, e_m)$. El segundo paso es comenzar con una segmentación Seg_0 , donde cada vértice v_{errt_i} está en su propio componente. Luego, construya Seg_p , dado Seg_p 1, de la siguiente manera: deje que v_{errt_i} y v_{errt_j} denotan los vértices conectados por la p -ésima arista en el orden, $e_p = (v_{errt_i}, v_{errt_j})$; si v_{errt_i} y v_{errt_j} están en componentes disjuntas de Seg_p 1 y w (e_p) es pequeño en comparación con la diferencia interna de ambos componentes, entonces combine los dos componentes, de lo contrario no haga nada (paso tres) La diferencia interna de un componente $C \subseteq \text{Vert}$ se define como el mayor peso en el árbol de expansión mínimo del componente MinST (C, Edg) que es IntDiff (C), que se muestra en la siguiente ecuación.

$$A = \max_{ee \in \text{MinST}(C, E, d, g) \in \text{Edg}} * W((v_{errt_i}, v_{errt_j})) \quad (7)$$

La diferencia entre dos componentes $C_1, C_2 \subseteq \text{Vert}$ se define como el borde de peso mínimo que conecta los dos

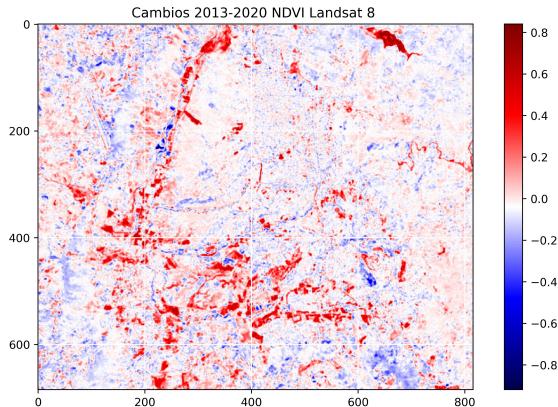


Fig. 1: Cambios de los valores de NDVI entre los años 2013 - 2020 en la zona de estudio

componentes.

$$B = \min_{vert_i \in \epsilon_1, vert_j \in \epsilon_2, (vert_i, vert_j) \in Edg} * W((verrt_i, verrt_j)) \quad (8)$$

La minima diferencia (minIntDiff) se define como:

$$\text{MinIntDiff}(c_1, c_2) = \text{Min}(A(c_1) + t(c_2), \text{Int}(C_2) + T(c_2)) \quad (9)$$

Donde t (C) es una función de umbral basada en el tamaño del componente, — C — denota el tamaño de C y k es algún parámetro constante:

$$t(c) = \frac{k}{|c|} \quad (10)$$

III. METODOLOGÍA

Las imágenes utilizadas para este estudio fueron del sensor landsat8 entre el intervalo del tiempo de 2013 a 2020, para acceder a estas se utilizó el google earth enginee (GEE). La zona de estudio se encuentra en los alrededores de la ciudad de Bucaramanga, departamento de Santander, Colombia. Una vez seleccionadas las imágenes con menor porcentaje de nubes para la zona se procede a calcular el NDVI (Normalized difference vegetation index) haciendo uso de este caso de la banda 5(infrarrojo cercano) y la banda 4(rojo) como se puede ver en la ecuación 1. Las longitudes de onda para las bandas 4 y 5 son de (0.64-0.67) y de (0.85-0.88) en micrómetros respectivamente, mientras que la resolución espacial de las dos bandas es de 30 metros [2].

$$NDVI = (Banda5 - Banda4) / (Banda5 + Banda4) \quad (1)$$

Una vez creadas las imágenes NDVI para la imágenes satelitales de los años 2013 y 2020 se comparan estas dos generando como resultado la figura 1, Se procede a crear histogramas con la finalidad de evidenciar cambios en los valores de cobertura vegetal en la zona, comprobando así que el cálculo de NDVI se realizó adecuadamente(figura 2) .

Se tomo la imagen NDVI del año 2013 como referencia para realizar las interpolaciones, se realizaron las interpolaciones

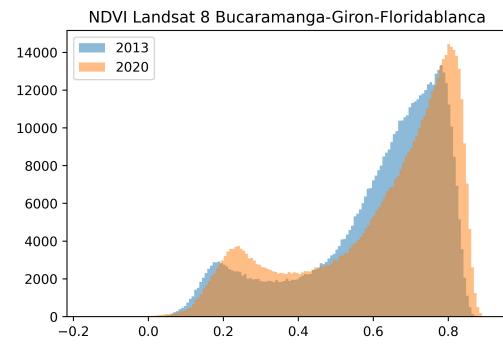


Fig. 2: Histograma distribuciones de pixeles para las imágenes NDVI del año 2013 y 2020

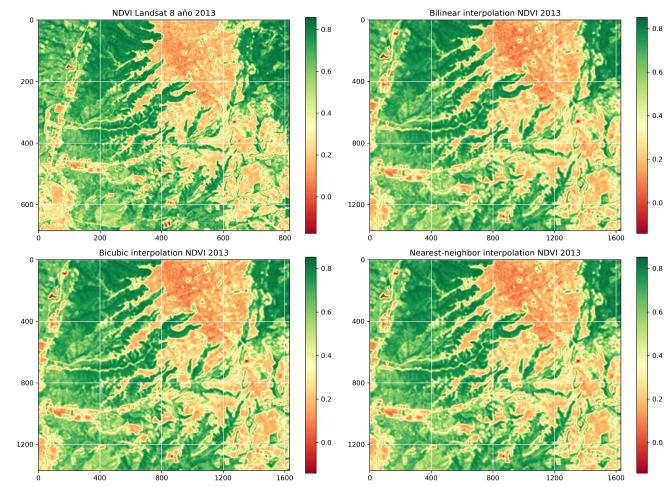


Fig. 3: Acercamiento de la imagen original y mejoradas mediante las diferentes interpolaciones utilizadas.

Bilineal, Cubica, Vecino más cercano a esta imagen, en estas tres interpolaciones se les especifico que debían generar el doble de los pixeles que había en la original. Los resultados obtenidos se encuentran en la figura 3, se realizó un acercamiento a las imágenes para facilitar la comparación visual entre estas. También se realizó un histograma con los valores originales de los pixeles(figura 4), así como de las interpolaciones para verificar que se habían creado nuevos pixeles en base a los existentes y poder analizar que valores se les asignaba a estos nuevos pixeles.

Con la finalidad de resaltar las diferencias entre los valores de pixeles nuevos de las 3 interpolaciones generadas, se generaron una serie de histogramas en las que se comparan estas (figura 5), facilitando así entender como opera cada uno de los algoritmos. También se visualizó a nivel visual dichas diferencias entre las dos interpolaciones que generaron el mayor numero de diferencias con la finalidad de ver cómo era esa distribución espacial (figura 6).

Como producto final se hizo uso de la imagen mejorada por la interpolación Bicubica para realizar la segmentación por super pixel mediante diferentes algoritmos, esto con la

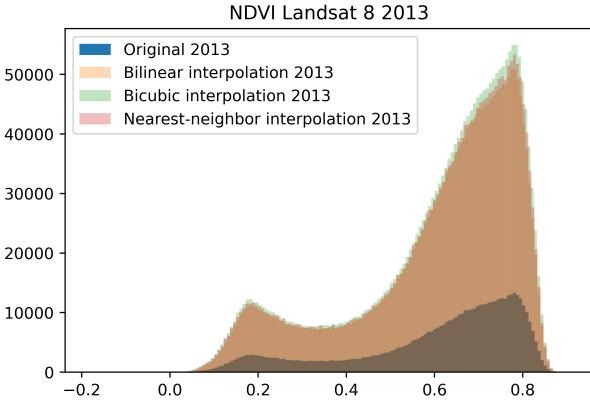


Fig. 4: Distribución de los valores de píxeles presentes en la imagen original NDVI de 2013 y de las interpolaciones realizadas

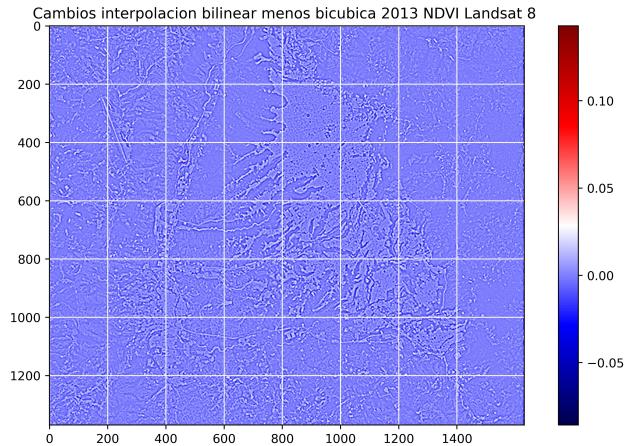


Fig. 6: Visualización de diferencias entre interpolación Bilineal y Bicubica

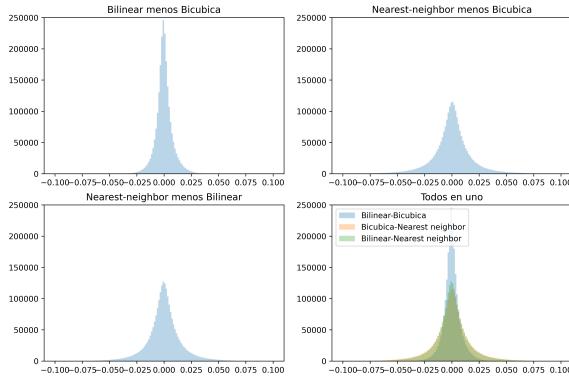


Fig. 5: Diferencias de los valores de píxeles entre las interpolaciones realizadas

intención de destacar cuál de estos sería de mayor utilidad a la hora de ser implementado en la creación de clases de usos de suelo con mayor o menor nivel de detalle, gracias a su funcionamiento (figura 7). Los algoritmos de segmentación por superpixel son SLIC, Compact watershed y Feizenszwalb.

IV. RESULTADO

Como resultados asociados a la investigación realizada sobre mejora de imágenes espectrales obtuvimos que en la zona de estudio se presenta una perdida clara de cobertura vegetal (figura 2), sustituyéndola por zonas urbanas o de suelo descubierto entre los años 2013 y 2020, esto producto del crecimiento de la población y la poca disponibilidad de espacio en la meseta de Bucaramanga, zona en la que se presenta la menor cantidad de cambios de uso de suelo relacionados con cobertura vegetal (figura 1).

A nivel de mejora de resolución espacial se logró mejorar con las diferentes interpolaciones mas o menos los 15 metros (figura 3). Dichas mejoras con valores nuevos creados en base a los cercanos, no generaron perdida en las distribuciones

originales como se muestra en la figura 4, sin embargo se logra evidenciar claramente que la interpolación Bicubica genera mayor cantidad de píxeles lo que permite obtener resultados más suaves a la hora de ver contornos, lo que podría facilitar la segmentación por superpixel.

Dada la alta cantidad de píxeles con diferencias que se dan entre las interpolaciones Bilineal y Bicubica llegando a 250.00 valores donde estas se concentran cercanas a cero sin ser mayores a 0.025 en magnitud como se ve en la figura 5. Se genera un efecto de segmentación en las zonas que presentan cambios bruscos en el NDVI, dichas zonas son los puntos donde se encuentran las zonas urbanas y las zonas con cobertura vegetal saludable. Permitiendo así realizar un segmentación de los centros urbanos o las zonas donde no hay cobertura vegetal como se ve en la figura 6.

Al comparar los resultados obtenidos de la segmentación por super pixel generada por los algoritmos SLIC, Compact watershed y Feizenszwalb sobre la imagen mejorada con interpolación bicubica (figura 7) se logra evidenciar que Feizenszwalb provee un mayor nivel de detalle seguido por SLIC y por último Feizenszwalb. Dicho nivel de detalle estará relacionado con la capacidad de generar diferentes categorías en el uso de suelo en base a la cobertura vegetal de la zona.

V. CONSIDERACIONES FINALES

La utilización de algoritmos de interpolación unido con algoritmos de segmentación por super pixel permite generar resultados que conservan la esencia de la imagen original y facilitan la clasificación de los diferentes valores que representaría usos de suelo en este caso de NDVI producto de dos de las bandas de la imagen satelitalpectral del sensor landsat 8 .

Al visualizar las diferencias generadas entre las interpolaciones Bilineal y Bicubica de la imagen NDVI se puede llegar a resaltar las zonas donde se dan contrastes grandes de valores como lo son centros urbanos o zonas sin cobertura vegetal. Permitiendo así generar una segmentación que solo se enfoca

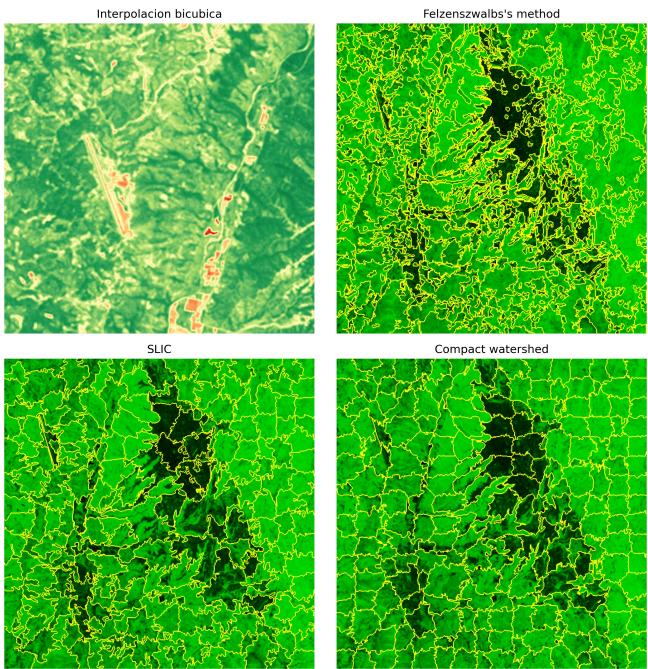


Fig. 7: Resultados de la segmentación por super pixel de la imagen mejorada con interpolacion bicubica

en esta zonas y facilitando la visualización de los contornos de estas.

REFERENCES

- [1] Alin-Florin, Patricia-Steliana, Giorgiana Violeta, Marcel Prodan "ON IMAGE SEGMENTATION USING A COMBINATION OF FELZENZSWALB, SLIC AND WATERSHED METHODS" JOURNAL OF INFORMATION SYSTEMS OPERATIONS MANAGEMENT, Vol. 14.1, May 2020
- [2] Lalitha K, Amrutha R, Michahial S, Shivakumar M. Implementation of watershed segmentation. Int J Adv Res Comput Commun Eng. 2016
- [3] Landsat 8 (L8) Data Users Handbook (2016) Department of the Interior U.S. Geological Survey. <https://landsat.usgs.gov/sites/default/files/documents/Landsat8DataUsersHa>
- [4] P. Hurtik and N. Madrid, "Bilinear interpolation over fuzzified images: enlargement," inThe 2015 IEEE International Conference on FuzzySystems (FUZZ-IEEE 2015), 2015.
- [5] R. Achanta, A. Shaji, K. Smith, A. Lucchi, P. Fua, and S. Susstrunk. Slic superpixels. Technical report, 2010.
- [6] R. Keys, "Cubic Convolution Interpolation for Digital Image Processing", IEEE Transactions on Acoustics, Speech, and Signal Processing, 29(6), 1981. <http://dx.doi.org/10.1109/TASSP.1981.1163711>.
- [7] Shreyas Fadnavis "Image Interpolation Techniques in Digital Image Processing: An Overview" Pune Institute of Computer Technology, Pune University, India, October 2014